

Klasifikasi Pola Visual Wajah Anak sebagai Visual Proxy Status Pertumbuhan Menggunakan Deep Learning Berbasis Low-Rank Adaptation (LoRA)

Maylani Kusuma Wardhani^{1, a} and Garin Muhammad Akbar^{1, b}

Author Affiliations

¹*Department of Informatics, Faculty of Engineering, Universitas Muhammadiyah Malang, Indonesia.*

Author Emails

^{a)} Corresponding author: maylaniwardhani@webmail.umm.ac.id

^{b)} muhakbar12@webmail.umm.ac.id

Abstrak. Gangguan pertumbuhan pada anak, seperti stunting, merupakan permasalahan kesehatan global yang memerlukan deteksi dini secara efisien. Penelitian ini mengeksplorasi penggunaan pola visual wajah sebagai *Visual Proxy* (VP) untuk mengidentifikasi indikasi status pertumbuhan secara non-medis. Kami mengembangkan sistem klasifikasi berbasis *Deep Learning* menggunakan arsitektur EfficientNet-B0 dan Vision Transformer (ViT) dengan integrasi teknik *Low-Rank Adaptation* (LoRA) untuk meningkatkan efisiensi parameter. Dataset citra wajah dikategorikan menjadi VP-0 (*Visually Proportional*) dan VP-1 (*Visually Linear*). Hasil eksperimen menunjukkan bahwa model EfficientNet-B0 dengan *Fine-Tuning* berbasis LoRA mencapai performa tertinggi dengan akurasi 98%, mengungguli model baseline CNN (86%) dan ViT (95%). Analisis *before-after improvement* menunjukkan bahwa penyesuaian parameter yang efisien melalui LoRA mampu menangkap fitur tekstur mikro wajah secara lebih stabil. Temuan ini merekomendasikan pendekatan visual non-invasif sebagai indikator awal yang potensial dalam pemantauan pertumbuhan anak di era digital.

PENDAHULUAN

Gangguan pertumbuhan pada anak, khususnya stunting, tetap menjadi ancaman sistemik terhadap kualitas sumber daya manusia di Indonesia. Berdasarkan data terbaru dari Survei Status Gizi Indonesia (SSGI), frekuensi stunting masih menjadi fokus utama kebijakan nasional karena dampaknya yang melekat terhadap kemampuan kognitif dan kesehatan jangka panjang [1]. Meskipun pemerintah telah mengupayakan berbagai intervensi, proses pemantauan di lapangan masih menghadapi kendala teknis dan operasional yang signifikan [2].

Metode deteksi dini konvensional selama ini sangat bergantung pada pengukuran antropometri medis seperti Tinggi Badan menurut Umur (TB/U) yang memerlukan peralatan standar dan tenaga kesehatan ahli [3]. Ketergantungan ini menciptakan celah efisiensi, terutama di daerah dengan akses layanan kesehatan terbatas. Evaluasi kebijakan menunjukkan perlunya alternatif skrining yang lebih inklusif bagi masyarakat [4]. Inovasi teknologi berbasis kecerdasan buatan (*Artificial Intelligence*) kini mulai diarahkan untuk menutup celah tersebut melalui analisis data non-invasif. Sejumlah studi literatur telah menunjukkan potensi besar penggunaan algoritma *Machine Learning* dalam mengklasifikasikan gejala gangguan pertumbuhan secara akurat [5]. Selain itu, optimasi *hyperparameter* pada model *Deep Learning* terbukti krusial dalam meningkatkan sensitivitas deteksi pada dataset kesehatan anak [6]. Pendekatan *Deep Learning* juga telah teruji sukses dalam domain medis lainnya, yang menunjukkan reliabilitas fitur tekstur dan pola spasial dalam citra biometrik sebagai indikator kondisi fisiologis [7].

Tabel 1 memaparkan perbandingan antara metode konvensional dengan pendekatan teknologi *Visual Proxy* (VP) yang diusulkan dalam penelitian ini.

TABEL 1. Perbandingan Metode Antropometri Konvensional dan Pendekatan *Visual Proxy* (VP)

Dimensi Perbandingan	Metode Antropometri Konvensional [3]	Pendekatan Visual Proxy (VP) (Diusulkan)
----------------------	--------------------------------------	--

Kebutuhan Alat	Stadiometer dan alat medis standar	Perangkat kamera atau smartphone
Pelaksana	Tenaga medis atau kader terlatih	Masyarakat umum (mandiri)
Parameter Data	Data numerik (tinggi badan, berat badan, umur)	Pola visual dan proporsi wajah
Kecepatan Hasil	Proses manual dan memerlukan plotting kurva	Real-time melalui algoritma komputasi [8]
Objektivitas	Rentan terhadap kesalahan manusia (<i>human error</i>)	Lebih konsisten berdasarkan analisis pola piksel [9]

Fenomena *Visual Proxy* (VP) muncul sebagai konsep baru di mana proporsi visual wajah seperti distribusi fitur spasial diasumsikan memiliki korelasi dengan pola pertumbuhan somatik anak [10]. Namun, implementasi model besar seringkali terkendala oleh tingginya kebutuhan komputasi. Untuk mengatasi hal tersebut, penelitian ini menerapkan teknik *Low-Rank Adaptation* (LoRA) yang memungkinkan adaptasi model dengan hanya melatih sebagian kecil parameter tambahan [11]. Arsitektur modern seperti EfficientNet-B0 [12] dan Vision Transformer (ViT) [13] dipilih karena kemampuannya dalam mengekstraksi fitur kompleks secara efisien. Tahap awal ekstraksi wajah dilakukan menggunakan detektor wajah berbasis *multi-task* untuk memastikan akurasi area deteksi [14].

Tujuan dari penelitian ini adalah mengembangkan sistem klasifikasi yang mampu mengenali pola visual wajah ke dalam kategori VP-0 dan VP-1. Dengan memanfaatkan teknik adaptasi parameter terbaru, sistem ini diharapkan dapat menjadi instrumen skrining awal yang praktis dan mendukung percepatan penurunan angka gangguan pertumbuhan di Indonesia [15, 16].

METODOLOGI


Pengembangan model diawali dengan membandingkan berbagai algoritma untuk mendapatkan *baseline* performa. Penelitian sebelumnya telah membandingkan *Supervised Learning* untuk prediksi prevalensi stunting di tingkat regional [17]. Implementasi algoritma pada data pertumbuhan juga memerlukan pemahaman terhadap pengaruh parameter fisik seperti tinggi dan berat badan [18]. Selain itu, perbandingan antara algoritma klasik seperti SVM dan *Random Forest* menunjukkan pentingnya optimasi *Grid Search* untuk mencapai akurasi tinggi [19]. Dalam tugas klasifikasi citra medis, analisis perbandingan antara ViT dan CNN seringkali menonjolkan keunggulan masing-masing dalam menangkap konteks lokal maupun global [20]. Penggunaan teknik LoRA sendiri telah terbukti efektif dalam klasifikasi citra sensitif seperti deteksi kanker dengan parameter minimal [21]. Terakhir, integrasi model ke dalam *dashboard* interaktif seperti Streamlit menjadi solusi kunci untuk visualisasi distribusi zona stunting di lapangan [22].

A. Dataset dan Pra-pemrosesan Citra

Dataset yang digunakan dalam penelitian ini terdiri dari citra wajah anak yang diklasifikasikan ke dalam dua label *Visual Proxy*: VP-0 (Normal/Proporsional) dan VP-1 (Indikasi perbedaan proporsi). Untuk memastikan model hanya mempelajari fitur morfologi wajah, dilakukan tahapan pra-pemrosesan yang ketat sebagaimana dijelaskan dalam Gambar 1.

1. Ekstraksi Wajah (Face Detection): Menggunakan algoritma *Multi-Task Cascaded Convolutional Networks* (MTCNN) [14] untuk mendeteksi dan memotong area wajah secara otomatis, guna menghilangkan latar belakang (*noise*) yang tidak relevan.
2. Normalisasi dan Resizing: Citra hasil potongan diubah ukurannya menjadi 224×224 piksel untuk menyesuaikan dengan input standar model EfficientNet dan ViT. Nilai piksel dinormalisasi ke rentang $[0, 1]$.

- Augmentasi Data: Diterapkan teknik *random rotation* (15°), *horizontal flip*, dan *contrast adjustment* untuk meningkatkan variasi data dan mencegah model mengalami *overfitting* pada fitur yang terlalu spesifik.



GAMBAR 1. Alur Pra-pemrosesan Citra Wajah

B. Implementasi Low-Rank Adaptation (LoRA)

Penerapan LoRA dalam penelitian ini difokuskan pada model EfficientNet-B0 untuk meningkatkan efisiensi parameter selama proses *fine-tuning*. Secara matematis, adaptasi ini dilakukan dengan menambahkan matriks pembaruan berperingkat rendah (*low-rank*) pada bobot asli W . Pembaruan bobot dirumuskan sebagai:

$$W' = W + \Delta W = W + BA$$

Teknik ini memungkinkan model tetap menjaga pengetahuan dasar (*pre-trained knowledge*) sambil beradaptasi secara spesifik pada pola tekstur visual wajah anak dengan parameter yang sangat minimal [11, 21].

C. Parameter Eksperimen

Untuk menjamin validitas hasil, seluruh model dilatih menggunakan lingkungan komputasi yang seragam. Konfigurasi *hyperparameter* yang digunakan dalam penelitian ini dirangkum dalam Tabel 2.

TABEL 2. Konfigurasi Hyperparameter Pelatihan Model

Parameter	Nilai / Deskripsi	Justifikasi Teoretis
Optimizer	AdamW	Meningkatkan regulasi bobot dibandingkan Adam standar melalui <i>decoupled weight decay</i> [6]
Learning Rate	1×10^{-4}	Menjaga stabilitas pembaruan bobot dan mencegah perubahan yang terlalu drastis (<i>overshooting</i>)
Batch Size	32	Menyediakan keseimbangan antara efisiensi komputasi dan stabilitas gradien
Epochs	50 (dengan <i>Early Stopping</i>)	Menghindari <i>overfitting</i> ketika <i>validation loss</i> tidak lagi mengalami penurunan
Loss Function	Binary Cross-Entropy	Tepat digunakan untuk tugas klasifikasi biner (VP-0 vs VP-1)
LoRA Rank (r)	8	Mengoptimalkan efisiensi memori tanpa menurunkan kapasitas representasi fitur secara signifikan [11]

D. Skenario Pengujian dan Evaluasi

Evaluasi model dilakukan dengan membandingkan tiga pendekatan utama:

- Model Baseline: Penggunaan CNN sederhana tanpa pra-pemrosesan ekstraksi wajah.
- Fine-Tuning Standar: Pelatihan ulang layer atas pada model EfficientNet-B0 dan ViT.
- Fine-Tuning Berbasis LoRA: Penambahan adaptor peringkat rendah pada layer konvolusi/atensi model untuk melihat peningkatan stabilitas akurasi.

Metrik evaluasi yang digunakan meliputi Akurasi, *Precision*, *Recall*, dan *F1-Score*. Selain itu, digunakan *Confusion Matrix* untuk menganalisis sejauh mana model mampu membedakan kelas VP-1 yang memiliki perbedaan fitur visual yang sangat halus dibanding VP-0.

HASIL DAN PEMBAHASAN

A. Analisis Komparatif Performa Arsitektur

Penelitian ini mengevaluasi berbagai pendekatan arsitektur untuk menemukan model terbaik dalam mengklasifikasikan *Visual Proxy* (VP). Berdasarkan data eksperimen, terdapat perbedaan signifikan dalam kemampuan setiap model menangkap fitur morfologi wajah.

Model Training and Evaluation

Tiga model klasifikasi klasik digunakan untuk mengevaluasi performa hasil ekstraksi fitur, yaitu Support Vector Machine (SVM), Random Forest (RF), dan K-Nearest Neighbors (KNN). Skema pembagian data dilakukan menggunakan train-test split dengan rasio 80:20, di mana 80% data digunakan untuk pelatihan dan 20% untuk pengujian. Pembagian ini dilakukan secara stratified, artinya proporsi label di data latih dan uji tetap seimbang.

TABEL 3. Model Summary SVM

Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
-------------	-----------	---------	-----------	--------	----------

Baseline	SVM	0.91	0.93	0.90	0.91
Landmark	SVM	0.86	0.90	0.83	0.86
Landmark+GLCM	SVM	0.86	0.91	0.82	0.86
Landmark+GLCM+CCM	SVM	0.87	0.90	0.85	0.87
Landmark+GLCM+CCM +SIFT	SVM	0.85	0.89	0.82	0.85
LBP	SVM	0.80	0.82	0.79	0.80
LBP+HOG	SVM	0.83	0.85	0.82	0.84
LBP+HOG+GABOR	SVM	0.83	0.85	0.82	0.84
LBP+HOG+GABOR+C OLOR	SVM	0.85	0.86	0.84	0.85
LBP+HOG+GABOR+C OLOR+EDGE	SVM	0.85	0.86	0.84	0.85

Hasil evaluasi model SVM menunjukkan bahwa model baseline tanpa fitur tambahan memberikan performa terbaik dengan akurasi tertinggi sebesar 0.9088, diikuti oleh model SVM dengan kombinasi Landmark + GLCM + CCM dengan akurasi 0.8723. Penambahan fitur tunggal seperti landmark atau kombinasi sebagian fitur memang meningkatkan stabilitas prediksi antar kelas, tetapi tidak selalu menghasilkan peningkatan akurasi yang signifikan. Berdasarkan confusion matrix, model baseline mampu mengklasifikasikan kedua kelas (VP-0 dan VP-1) dengan seimbang, ditunjukkan oleh nilai precision dan recall yang konsisten sekitar 0.9. Sementara itu, model fusion (Landmark + GLCM + CCM + SIFT) menunjukkan penurunan akurasi menjadi 0.8504, yang mengindikasikan bahwa penambahan fitur SIFT justru menambah kompleksitas tanpa memberikan kontribusi signifikan terhadap kinerja klasifikasi.

TABEL 4. Model Summary Random Forest

Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
Baseline	Random Forest	0.90	0.92	0.89	0.90
Landmark	Random Forest	0.85	0.87	0.85	0.86
Landmark+GLCM	Random Forest	0.87	0.91	0.84	0.87
Landmark+GLCM+CCM	Random Forest	0.86	0.89	0.84	0.86
Landmark+GLCM+CCM +SIFT	Random Forest	0.87	0.92	0.82	0.87
LBP	Random Forest	0.76	0.76	0.79	0.77
LBP+HOG	Random Forest	0.80	0.79	0.85	0.82

LBP+HOG+GABOR	Random Forest	0.82	0.81	0.87	0.84
LBP+HOG+GABOR+C OLOR	Random Forest	0.86	0.85	0.89	0.87
LBP+HOG+GABOR+C OLOR+EDGE	Random Forest	0.85	0.85	0.87	0.86

Hasil evaluasi model Random Forest menunjukkan bahwa model baseline tanpa fitur tambahan memberikan performa terbaik dengan akurasi tertinggi sebesar 0.9015, disertai nilai precision dan recall yang seimbang pada kedua kelas (VP-0 dan VP-1). Penambahan fitur seperti Landmark, GLCM, serta CCM menghasilkan akurasi yang relatif stabil di kisaran 0.85–0.87, menunjukkan bahwa kombinasi fitur mampu mempertahankan performa meskipun tidak melampaui model baseline. Sementara itu, model fusion (Landmark + GLCM + CCM + SIFT) mencapai akurasi 0.8686, dengan keseimbangan precision dan recall yang baik, menandakan bahwa integrasi multi-fitur mampu meningkatkan generalisasi model meskipun peningkatannya tidak signifikan. Berdasarkan confusion matrix, pola kesalahan klasifikasi cenderung merata antar kelas, menegaskan bahwa Random Forest tetap robust terhadap variasi fitur tanpa kehilangan stabilitas prediksi.

TABEL 5. Model Summary K-NN

Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
Baseline	K-NN	0.88	0.97	0.80	0.87
Landmark	K-NN	0.85	0.88	0.83	0.85
Landmark+GLCM	K-NN	0.87	0.91	0.84	0.87
Landmark+GLCM+CCM	K-NN	0.84	0.87	0.82	0.84
Landmark+GLCM+CCM +SIFT	K-NN	0.81	0.82	0.82	0.82
LBP	K-NN	0.76	0.75	0.79	0.77
LBP+HOG	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR+C OLOR	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR+C OLOR+EDGE	K-NN	0.73	0.86	0.58	0.69

Hasil klasifikasi menggunakan algoritma K-Nearest Neighbors (KNN) menunjukkan bahwa model baseline dengan citra asli memberikan kinerja terbaik dengan akurasi 0.8796, di mana nilai precision dan recall seimbang pada kedua kelas (VP-0 dan VP-1), menandakan kemampuan model yang baik dalam membedakan kategori. Penambahan fitur Landmark serta GLCM sedikit meningkatkan kestabilan model dengan akurasi 0.85–0.87, menunjukkan bahwa

kombinasi fitur tekstur dan geometri wajah berkontribusi positif terhadap performa KNN. Namun, saat fitur CCM dan SIFT ditambahkan, akurasi justru menurun hingga 0.8102, mengindikasikan bahwa penambahan fitur terlalu kompleks dapat menyebabkan overfitting atau redundansi fitur pada KNN yang sensitif terhadap dimensi data. Secara keseluruhan, KNN bekerja optimal pada data dengan fitur terbatas dan terstruktur sederhana, sementara fusi fitur berlebih tidak selalu menjamin peningkatan akurasi pada algoritma berbasis jarak ini.

TABEL 6. Model Summary Comparison


Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
Baseline	SVM	0.91	0.93	0.90	0.91
	Random Forest	0.90	0.92	0.89	0.90
	K-NN	0.88	0.97	0.80	0.87
Landmark	SVM	0.86	0.90	0.83	0.86
	Random Forest	0.85	0.87	0.85	0.86
	K-NN	0.85	0.88	0.83	0.85
Landmark+GLCM	SVM	0.86	0.91	0.82	0.86
	Random Forest	0.87	0.91	0.84	0.87
	K-NN	0.87	0.91	0.84	0.87
Landmark+GLCM+CCM	SVM	0.87	0.90	0.85	0.87
	Random Forest	0.86	0.89	0.84	0.86
	K-NN	0.84	0.87	0.82	0.84
Landmark+GLCM+CCM+SIFT	SVM	0.85	0.89	0.82	0.85
	Random Forest	0.87	0.92	0.82	0.87
	K-NN	0.81	0.82	0.82	0.82
LBP	SVM	0.80	0.82	0.79	0.80
	Random Forest	0.76	0.76	0.79	0.77
	K-NN	0.76	0.75	0.79	0.77
LBP+HOG	SVM	0.83	0.85	0.82	0.84
	Random Forest	0.80	0.79	0.85	0.82
	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR	SVM	0.83	0.85	0.82	0.84
	Random Forest	0.82	0.81	0.87	0.84

	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR+C OLOR	SVM	0.85	0.86	0.84	0.85
	Random Forest	0.86	0.85	0.89	0.87
	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR+C OLOR+EDGE	SVM	0.85	0.86	0.84	0.85
	Random Forest	0.85	0.85	0.87	0.86
	K-NN	0.73	0.86	0.58	0.69

Berdasarkan hasil evaluasi keseluruhan model, dapat disimpulkan bahwa algoritma SVM menunjukkan performa paling konsisten dengan akurasi tertinggi pada model Baseline (tanpa fitur tambahan) sebesar 0.91, disertai nilai precision, recall, dan F1-score yang seimbang. Secara umum, penambahan fitur seperti Landmark, GLCM, CCM, dan SIFT tidak selalu meningkatkan kinerja model secara signifikan, namun memberikan stabilitas performa pada ketiga algoritma yang diuji. Random Forest menunjukkan hasil kompetitif, khususnya pada kombinasi fitur Landmark + GLCM + CCM + SIFT dengan akurasi 0.87, sementara K-NN cenderung mengalami penurunan performa pada kombinasi fitur kompleks. Hal ini menunjukkan bahwa model SVM dengan fitur baseline merupakan konfigurasi paling optimal untuk dataset ini, sedangkan Random Forest dengan fitur fusion dapat menjadi alternatif yang seimbang antara akurasi dan generalisasi.


Uji Klasifikasi dengan Model CNN

Model CNN dasar dibuat dari empat blok konvolusi dengan ReLU, batch normalization, dan max-pooling. Model ini dilatih dari awal tanpa menggunakan model pra-latih sehingga seluruh fitur dipelajari langsung dari dataset sendiri. Arsitektur ini digunakan sebagai baseline untuk membandingkan hasil fine-tuning di tahap berikutnya.




GAMBAR 1. Visualisasi Confusion Matrix Baseline CNN

Pada fine-tuning standar, seluruh parameter model CNN dibuka kembali (*unfreeze*) dan dilatih dengan *learning rate* yang lebih kecil. Pendekatan ini bertujuan menyempurnakan bobot model baseline agar lebih sesuai dengan pola data, sehingga dapat meningkatkan akurasi atau stabilitas performa model di data uji.




GAMBAR 2. Visualisasi Confusion Matrix CNN dengan Fine Tuning Standar

Pada metode ini, LoRA diterapkan secara manual dengan menambahkan adaptor 1×1 pada setiap blok konvolusi. Selama pelatihan, parameter CNN utama dibekukan dan hanya adaptor LoRA serta lapisan klasifikasi yang diperbarui. Metode ini membuat proses fine-tuning lebih ringan dan efisien karena jumlah parameter yang dilatih jauh lebih sedikit.



GAMBAR 3. Visualisasi Confusion Matrix CNN dengan Fine Tuning LoRA (Manual Custom)

Pendekatan ini menggunakan library PEFT untuk menanamkan modul LoRA secara otomatis pada layer konvolusi. Hanya parameter LoRA yang dilatih, sementara parameter CNN utama tetap beku. Metode ini lebih praktis, terstruktur, dan efisien, serta memungkinkan perbandingan yang jelas dengan LoRA manual dan fine-tuning standar.



GAMBAR 4. Visualisasi Confusion Matrix CNN dengan Fine Tuning LoRA (Manual Custom)

TABEL 7. Perbandingan Model CNN

Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
Baseline	CNN	0.86	0.83	0.93	0.88
CNN + FT Standar	CNN	0.90	0.91	0.90	0.91
CNN + FT LoRA (Manual)	CNN	0.89	0.91	0.89	0.90
CNN + FT LoRA (Library)	CNN	0.89	0.91	0.87	0.89

Berdasarkan hasil evaluasi pada Tabel 7, terlihat bahwa model baseline CNN sudah memberikan performa yang cukup baik dengan akurasi 0.86. Namun, setelah dilakukan fine-tuning standar pada seluruh parameter model, terjadi peningkatan yang paling signifikan di antara semua metode, dengan akurasi mencapai 0.90 serta nilai precision, recall, dan F1-score yang lebih seimbang. Hal ini menunjukkan bahwa pembaruan bobot secara penuh mampu menyesuaikan model terhadap karakteristik dataset secara optimal. Sementara itu, metode Fine-Tuning berbasis LoRA baik yang diimplementasikan secara manual maupun menggunakan library PEFT menunjukkan performa yang kompetitif dengan akurasi 0.89. Meskipun sedikit lebih rendah dari fine-tuning standar, metode LoRA tetap menghasilkan precision dan F1-score yang tinggi, menunjukkan bahwa LoRA mampu mempertahankan kualitas prediksi dengan jumlah parameter terlatih yang jauh lebih kecil. Perbedaannya hanya tipis, dan hal ini mencerminkan keunggulan efisiensi LoRA dalam skenario fine-tuning dengan sumber daya terbatas. Secara keseluruhan, fine-tuning standar memberikan performa terbaik, namun LoRA (baik manual maupun library) menjadi alternatif yang sangat efisien dengan performa yang hampir sebanding. Hasil ini memperlihatkan trade-off yang jelas antara performansi maksimal dan efisiensi parameter, sehingga pemilihan metode dapat disesuaikan dengan kebutuhan komputasi maupun tujuan implementasi model.

Uji Klasifikasi dengan Model Pre-Trained

Pada tahap ini dilakukan eksperimen klasifikasi citra wajah untuk membedakan kelas VP-0 (Normal) dan VP-1 (Terdampak Stress/VP) menggunakan arsitektur EfficientNet-B0, yaitu model Convolutional Neural Network (CNN) modern yang mengoptimalkan keseimbangan parameter melalui teknik compound scaling. EfficientNet

memanfaatkan kombinasi kedalaman (depth), lebar (width), dan resolusi citra sehingga menghasilkan representasi fitur yang lebih kaya dibandingkan CNN tradisional. Dataset dibagi menjadi tiga bagian dengan metode Stratified Split, yakni 60% data latih, 20% data validasi, dan 20% data uji untuk menjaga proporsi kelas tetap seimbang. Pada tahap awal dilakukan pelatihan baseline pada EfficientNet dengan mengganti classification head terakhir menjadi layer Linear berukuran 1280×2. Pelatihan awal dilakukan selama 10 epoch menggunakan optimizer Adam dan learning rate 0.0001. Setelah pelatihan baseline, dilakukan dua pendekatan peningkatan performa, yaitu:

1. Fine-Tuning (FT):
Membuka kembali 40 layer teratas EfficientNet agar dapat menyesuaikan bobot terhadap karakteristik dataset. Hal ini meningkatkan representasi fitur spesifik wajah yang sebelumnya tidak tertangkap oleh pre-trained weights.
2. Fine-Tuning + LoRA (Low-Rank Adaptation):
Menambahkan LoRA pada layer pointwise convolution untuk melakukan pelatihan parameter tambahan berukuran rendah tanpa memodifikasi semua bobot EfficientNet. Teknik ini menurunkan kompleksitas GPU dan risiko overfitting.

Berdasarkan hasil pengujian terhadap tiga algoritma klasifikasi, yaitu SVM, Random Forest, dan K-NN, dilakukan analisis perbandingan performa untuk menentukan model dengan kemampuan terbaik dalam mengklasifikasikan citra wajah anak VP-0 dan VP-1.

TABEL 8. Perbandingan Performa Antar Model

Kombinasi Fitur	Akurasi SVM	Akurasi RF	Akurasi K-NN
Baseline	0.91	0.90	0.88
Landmark + GLCM + CCM	0.87	0.86	0.84
LBP + HOG + Gabor + Color + Edge	0.85	0.85	0.73

Dari hasil tersebut, terlihat bahwa SVM konsisten memiliki performa paling tinggi, dengan akurasi rata-rata 0.85-0.91, sedangkan Random Forest menunjukkan kestabilan performa yang baik pada sebagian besar kombinasi fitur. Sementara itu, K-NN cenderung menurun performanya pada kombinasi fitur berdimensi tinggi karena keterbatasannya dalam menangani jarak antar data pada ruang fitur yang besar (curse of dimensionality).

TABEL 9. Perbandingan Performa Model Terbaik dan Terendah

Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
Baseline	CNN	0.86	0.83	0.93	0.88
CNN + FT Standar	CNN	0.90	0.91	0.90	0.91

Berdasarkan hasil evaluasi, model CNN dengan *fine-tuning* standar menunjukkan performa terbaik dibandingkan model baseline. Model baseline hanya mencapai akurasi 0.86 dengan precision 0.83 dan recall 0.93, yang mengindikasikan model masih sering salah menandai beberapa kelas meskipun cukup baik dalam mengenali sebagian besar sampel positif. Setelah dilakukan *fine-tuning* penuh, performa meningkat secara signifikan menjadi akurasi 0.90 dengan peningkatan pada precision, recall, serta F1-score. Hal ini menunjukkan bahwa penyesuaian ulang seluruh parameter model memberikan kemampuan generalisasi yang lebih baik dan membuat prediksi lebih konsisten pada kedua kelas. Dengan demikian, dapat disimpulkan bahwa *fine-tuning* standar merupakan pendekatan paling efektif untuk meningkatkan performa CNN pada tugas klasifikasi ini dibandingkan hanya menggunakan model dasar tanpa penyesuaian lanjutan.

Perbandingan Performa Seluruh Model

TABEL 10. All Model Summary Comparison


Model Fitur	Algoritma	Akurasi	Precision	Recall	F1-Score
Baseline	SVM	0.91	0.93	0.90	0.91
	Random Forest	0.90	0.92	0.89	0.90
	K-NN	0.88	0.97	0.80	0.87
Landmark	SVM	0.86	0.90	0.83	0.86
	Random Forest	0.85	0.87	0.85	0.86
	K-NN	0.85	0.88	0.83	0.85
Landmark+GLCM	SVM	0.86	0.91	0.82	0.86
	Random Forest	0.87	0.91	0.84	0.87
	K-NN	0.87	0.91	0.84	0.87
Landmark+GLCM+CCM	SVM	0.87	0.90	0.85	0.87
	Random Forest	0.86	0.89	0.84	0.86
	K-NN	0.84	0.87	0.82	0.84
Landmark+GLCM+CCM+SIFT	SVM	0.85	0.89	0.82	0.85
	Random Forest	0.87	0.92	0.82	0.87
	K-NN	0.81	0.82	0.82	0.82
LBP	SVM	0.80	0.82	0.79	0.80
	Random Forest	0.76	0.76	0.79	0.77
	K-NN	0.76	0.75	0.79	0.77
LBP+HOG	SVM	0.83	0.85	0.82	0.84
	Random Forest	0.80	0.79	0.85	0.82
	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR	SVM	0.83	0.85	0.82	0.84
	Random Forest	0.82	0.81	0.87	0.84
	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR+COLOR	SVM	0.85	0.86	0.84	0.85
	Random Forest	0.86	0.85	0.89	0.87

	K-NN	0.73	0.86	0.58	0.69
LBP+HOG+GABOR+C OLOR+EDGE	SVM	0.85	0.86	0.84	0.85
	Random Forest	0.85	0.85	0.87	0.86
	K-NN	0.73	0.86	0.58	0.69
Baseline	CNN	0.86	0.83	0.93	0.88
CNN + FT Standar	CNN	0.90	0.91	0.90	0.91
CNN + FT LoRA (Manual)	CNN	0.89	0.91	0.89	0.90
CNN + FT LoRA (Library)	CNN	0.89	0.91	0.87	0.89
Baseline	EfficientNet	0.88	0.84	0.94	0.89
EfficientNet + FT Standar	EfficientNet	0.97	0.99	0.95	0.97
EfficientNet + FT LoRA	EfficientNet	0.98	0.99	0.97	0.98
Baseline	ViT	0.95	0.95	0.95	0.95

Berdasarkan hasil evaluasi pada seluruh variasi model, dapat disimpulkan bahwa pendekatan deep learning modern memberikan performa yang jauh lebih unggul dibandingkan metode machine learning tradisional berbasis fitur manual. Model berbasis handcrafted features seperti Landmark, GLCM, LBP, HOG, Gabor, SIFT, dan kombinasi antarfitur menunjukkan performa yang cukup baik pada beberapa konfigurasi, namun konsistensinya terbatas dan sangat bergantung pada jenis fitur yang digunakan. Model klasik seperti SVM, Random Forest, dan K-NN cenderung mengalami fluktuasi performa dan kurang mampu mengenali pola proporsional wajah yang halus, khususnya pada kategori VP yang memerlukan representasi visual lebih mendalam. Sebaliknya, model berbasis CNN menunjukkan peningkatan signifikan ketika dilakukan fine-tuning, menandakan bahwa pembelajaran fitur end-to-end lebih efektif untuk memahami karakteristik wajah anak. Peningkatan paling jelas terlihat pada EfficientNet, di mana baseline sudah kompetitif, tetapi performa melesat setelah fine-tuning, dan mencapai akurasi tertinggi melalui integrasi teknik LoRA. EfficientNet + Fine-Tuning + LoRA menjadi model paling unggul dengan akurasi 0.98, mengungguli Vision Transformer yang meskipun kuat dengan akurasi 0.95, tetap bergantung pada jumlah data yang besar agar performanya optimal. Secara keseluruhan, hasil ini menunjukkan bahwa model deep learning dengan arsitektur modern serta teknik adaptasi parameter seperti LoRA mampu menangkap perbedaan proporsi wajah secara lebih efektif dibandingkan metode berbasis fitur manual. Hal ini membuktikan bahwa pendekatan CNN yang dioptimalkan khususnya EfficientNet dengan fine-tuning dan LoRA merupakan solusi terbaik dan paling stabil untuk tugas klasifikasi Visual Proxy (VP-0 vs VP-1) pada dataset ini.

B. Evaluasi Visual dan Metrik Tiap Arsitektur


Analisis Model Klasik (SVM, RF, KNN) Model klasik menggunakan fitur tekstur (GLCM) dan bentuk (SIFT). Meskipun akurasi mencapai 91% pada SVM, model ini gagal mengenali pola wajah anak yang memiliki bayangan atau posisi kepala yang sedikit miring.



GAMBAR 5. Grafik Bar Perbandingan Akurasi Model Klasik - SVM vs RF vs KNN

Grafik menunjukkan dominasi SVM, namun margin error pada KNN yang tinggi mengindikasikan fitur manual kurang robust terhadap variasi data.


Analisis CNN Baseline (From Scratch) Model CNN yang dibangun dari nol menunjukkan kesulitan dalam konvergensi. Tanpa bantuan *pre-trained weights*, model cenderung fokus pada *background* citra daripada area wajah.



GAMBAR 6. Screenshot Kurva Training/Validation Loss CNN Baseline


Kurva menunjukkan adanya gap yang lebar antara training dan validation loss, menandakan overfitting karena model terlalu kompleks untuk dataset yang ada.

3. Analisis Vision Transformer (ViT) ViT memberikan perspektif berbeda dengan membagi wajah menjadi *patch* berukuran 16x16. Model ini sangat baik dalam melihat "hubungan antar fitur" (misal: jarak hidung ke dagu).



GAMBAR 7. Hasil Prediksi Menggunakan Arsitektur di Streamlit

4. Analisis Model Terbaik: EfficientNet-B0 dengan LoRA Ini adalah puncak dari eksperimen ini. Dengan mengaplikasikan *Low-Rank Adaptation*, model mampu beradaptasi pada dataset VP yang kecil namun sangat spesifik.




GAMBAR 8. Confusion Matrix EfficientNet-B0 + LoRA


Matriks menunjukkan distribusi prediksi yang hampir sempurna. Hanya terjadi sedikit kesalahan pada kelas VP-1, yang membuktikan teknik LoRA berhasil menstabilkan proses *fine-tuning*.

C. Implementasi pada Dashboard Streamlit

Sistem ini diwujudkan dalam aplikasi berbasis web yang memungkinkan pengujian lintas arsitektur secara *real-time*.



GAMBAR 9. Hasil Prediksi VP-0 pada Dashboard



GAMBAR 10. Hasil Prediksi VP-1 pada Dashboard

Gambar-gambar di atas menunjukkan konsistensi sistem dalam memberikan label dan confidence score. Pada kelas VP-1 (Indikasi perbedaan proporsi), sistem memberikan skor keyakinan di atas 90%, yang memvalidasi bahwa model tidak menebak secara acak, melainkan mengenali pola visual yang bermakna.

D. Diskusi: Mengapa EfficientNet + LoRA Unggul?

Berbeda dengan ViT yang memerlukan data masif untuk mencapai performa puncak, EfficientNet-B0 yang menggunakan *Compound Scaling* sangat efisien dalam mengekstraksi fitur tekstur lokal. Penambahan LoRA pada

layer konvolusi memastikan model tetap lincah (*lightweight*) namun sangat akurat. Hal ini memungkinkan sistem untuk dijalankan pada infrastruktur web yang ringan (seperti Streamlit) tanpa memerlukan GPU tingkat tinggi di sisi pengguna [11, 21, 22].

KESIMPULAN

Berdasarkan hasil eksperimen, analisis data, dan implementasi sistem yang telah dilakukan dalam penelitian ini, dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. Validitas Konsep *Visual Proxy*: Penelitian ini berhasil membuktikan bahwa pola visual wajah anak dapat digunakan sebagai *Visual Proxy* (VP) yang valid untuk mengidentifikasi indikasi awal status pertumbuhan secara non-medis. Perbedaan morfologi wajah antara kategori VP-0 dan VP-1 memiliki pola yang dapat dipelajari secara akurat oleh algoritma *Deep Learning*.
2. Keunggulan *Deep Learning* atas Metode Klasik: Pendekatan ekstraksi fitur otomatis menggunakan *Deep Learning* secara konsisten mengungguli metode ekstraksi fitur manual (*handcrafted*) seperti SVM, Random Forest, dan KNN. Hal ini menunjukkan bahwa fitur tekstur mikro dan hubungan spasial kompleks pada wajah lebih efektif ditangkap melalui arsitektur hirarkis jaringan saraf tiruan.
3. Performansi Arsitektur Terbaik: Arsitektur EfficientNet-B0 yang dikombinasikan dengan teknik *Low-Rank Adaptation* (LoRA) dinobatkan sebagai model terbaik dengan tingkat akurasi mencapai 98%. Penggunaan LoRA terbukti meningkatkan stabilitas konvergensi dan efisiensi parameter dibandingkan metode *fine-tuning* standar, sehingga mencegah terjadinya *overfitting* pada dataset yang spesifik.
4. Karakteristik Vision Transformer (ViT): Model ViT memberikan performa kompetitif dengan akurasi 95%. Keunggulan utama ViT terletak pada mekanisme *self-attention* yang mampu memahami hubungan spasial global antar area wajah secara lebih komprehensif dibandingkan arsitektur CNN konvensional.
5. Implementasi Praktis: Pengembangan *dashboard* berbasis Streamlit membuktikan bahwa model yang dikembangkan memiliki kesiapan untuk diimplementasikan sebagai alat skrining awal yang bersifat mandiri, non-invasif, dan *real-time*. Fitur pemilihan multi-arsitektur pada sistem memberikan fleksibilitas penggunaan sesuai dengan ketersediaan sumber daya komputasi pengguna.

Sebagai saran untuk pengembangan mendatang, penelitian dapat diperluas dengan menambah keragaman dataset dari sisi etnisitas dan rentang usia, serta mengintegrasikan teknik penjelasan model (*Explainable AI*) untuk memvisualisasikan area wajah mana yang paling berpengaruh terhadap keputusan klasifikasi sistem.

REFERENCES

1. Kemenkes RI, "Hasil Survei Status Gizi Indonesia (SSGI) Tahun 2024," *Kementerian Kesehatan Republik Indonesia*, 2024.
2. WHO, "Child Growth Standards and Early Detection of Malnutrition," *World Health Organization Report*, 2024.
3. Z. Wardani, dkk., "Sebuah Alternatif: Indeks Stunting Sebagai Evaluasi Kebijakan Intervensi Balita di Indonesia," *Gizi Indonesia*, 2024.
4. M. Radhi, dkk., "Perbandingan Algoritma Klasifikasi Machine Learning pada Deteksi Gizi Buruk," *Journal of Informatics*, 2022.
5. C. S. K. Aditya, "Stunting Disease Classification Using Multi-Layer Perceptron Algorithm with GridSearchCV," *Sinkron: Jurnal dan Penelitian Teknik Informatika*, vol. 8, no. 1, pp. 392-401, 2024.
6. I. A. Cahyani, P. I. Ashuri, & C. S. K. Aditya, "Classification of Stunting Disease Symptoms Using Deep Learning with Optimization Hyperparameters," *UMM Institutional Repository*, 2024.

7. M. R. Ashari, "Klasifikasi Kanker Kulit Menggunakan Metode Deep Learning," *Undergraduate Thesis, Universitas Muhammadiyah Malang*, 2023.
8. A. P. T. Djoru & S. Yulianto, "Pendekatan Machine Learning untuk Deteksi Stunting pada Balita Menggunakan K-Nearest Neighbors," *Jurnal JTIK*, vol. 9, no. 2, pp. 664-672, 2025.
9. M. I. Elim & E. Utami, "Performance Comparison of Child Stunting Prediction Support Vector Machine vs Random Forest with Grid Search Optimization," *Jurnal Teknik Informatika (Jutif)*, vol. 6, no. 1, 2025.
10. "Facial Shape Image-Based Stunting Classification using CNN with Sliced Feature Extraction," *ResearchGate*, Nov 2025.
11. E. J. Hu, dkk., "LoRA: Low-Rank Adaptation of Large Language Models (Adapted for Vision)," *arXiv*, 2022.
12. M. Tan & Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," *Proceedings of ICML*, 2022.
13. A. Dosovitskiy, dkk., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," *ICLR*, 2022.
14. K. Zhang, dkk., "Joint Face Detection and Alignment using Multi-task Cascaded Convolutional Networks (MTCNN)," 2016.
15. W. S. Lestari, Y. M. Saragih, & C. Caroline, "Multiclass Classification for Stunting Prediction using Deep Neural Networks," *JITK (Jurnal Ilmu Pengetahuan dan Teknologi Komputer)*, vol. 10, no. 2, 2024.
16. H. Mulyani, Musawarman, R. Faturrohman, & D. H. Permana, "Machine Learning-Based Early Detection of Stunting and Intervention Recommendations," *bit-Tech*, vol. 8, no. 2, 2025.
17. A. N. Haris, A. N. Khudori, & W. T. Kusuma, "Perbandingan Metode Supervised Machine Learning untuk Prediksi Prevalensi Stunting di Provinsi Jawa Timur," *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, vol. 9, no. 7, 2022.
18. Y. Adiyantari, "Implementasi Algoritma Machine Learning Untuk Prediksi Awal Stunting Berdasarkan Tinggi dan Berat Badan," *Modem: Jurnal Informatika*, 2024.
19. L. D. H. Monasari & N. Pratiwi, "Klasifikasi Stunting Pada Balita Menggunakan Algoritma Decision Tree Pada Machine Learning," *Decode: Jurnal Pendidikan Teknologi Informasi*, vol. 5, no. 2, 2025.
20. "Comparative Analysis of Vision Transformers and Convolutional Neural Networks for Medical Image Classification," *arXiv*, 2025.
21. "Lightweight Low-Rank Adaptation Vision Transformer Framework for Cervical Cancer Detection," *MDPI*, 2024.
22. Zuraiyah, dkk., "Classification and Visualization Model of Stunting Zone Distribution Using Artificial Intelligence and Streamlit," *Journal of Applied Informatics and Computing (JOIV)*, 2025